

Visão Geral

Este projeto visa analisar o catálogo global de filmes e séries da Netflix para identificar tendências temporais, distribuição por dimensões (exemplo: distribuição por gênero/país) e métricas de desempenho. O objetivo é criar um pipeline de dados que transforme dados brutos em consultas que forneçam subsídios às tomadas de decisão. Foi utilizada a tecnologia em nuvem Databricks Community Edition para a construção de pipelines de dados, com a utilização de clusters. O projeto envolve a busca, coleta, modelagem, carga e análise de dados.

O dataset Netflix Movies and TV Shows contém as produções lançadas entre 1925 e 2021 e encontra-se em: https://www.kaggle.com/datasets/shivamb/netflix-shows?select=netflix_titles.csv.

Definição do problema

Este MVP tem como objetivo responder às seguintes questões:

- 1) **Questões de dimensão temporal** – conteúdos lançados entre 1925 e 2021:
 - 1.a) distribuição de conteúdo por ano de lançamento e tipo (filme ou seriado), incluindo a média de duração (minutos ou temporadas) -a análise temporal pode fornecer subsídios para retenção de usuários e para a criação de conteúdos, se as produções têm duração adequada.

A consulta exibe a distribuição de conteúdo, agrupada por tipo de conteúdo ("Movie" ou "TV Show") e ano de lançamento.

São exibidos os valores totais de cada tipo de conteúdo e duração média.

Se for filme ("Movie"), a duração é expressa em minutos. Se o tipo de conteúdo for "TV Show", a duração é expressa em número de temporadas
 - 1.b) Quantidade de lançamentos de produções (filmes e séries) agrupados por mês e ano – possibilita a análise de tendências históricas e verificar quais meses têm mais lançamentos. Esta análise é utilizada para a gestão planejar os lançamentos anuais, de acordo com os meses e tipos de conteúdo (filmes e séries).

- 1.c) Quantidade de títulos por ano, agrupada por tipo de conteúdo em forma tabular e gráfica. Esta análise gráfica permite avaliar a tendência de crescimento nas quantidades de lançamentos, por exemplo, se há crescimento linear, aumento exponencial, decréscimo.
- 2) Distribuição de classificações etárias – fornece subsídios para a Netflix optar para quais públicos (faixas etárias) investirá mais fortemente.
- 3) Países com mais produções por Gênero – agrupamento de países por gênero. Permite a resposta a seguintes questões: qual o país que produz mais comédias? Esta informação é relevante para a Netflix tomar sobre qual gênero investir em um determinado país.
- 4) Qual o tipo de conteúdo mais lançado pela Netflix, filmes ou séries e o percentual de cada um?
- 5) **Métricas de desempenho:**
 - 5.a) Top 10 diretores – ranking de diretores que mais lançaram conteúdo.
 - 5.b) Top 10 atores – ranking de diretores que mais atuaram;
 - 5.c) Top 10 gêneros – quais são os gêneros mais populares;
 - 5.d) Top 10 países – quais países possuem mais lançamentos.

Estrutura do trabalho

Todos os notebooks se encontram em:
https://github.com/Andrea68A/Puc_Ciencia_Dados/tree/MVP_Engenharia_Dados. Os links abaixo são evidências da criação dos notebooks no ambiente Databricks. O trabalho se encontra estruturado da seguinte forma:

000_Configurar_DBFS_e_pastas.ipynb

Este notebook é voltado para inicialização de valores e criação de pastas. Deve ser o primeiro a ser executado.

<https://databricks-prod-cloudfront.cloud.databricks.com/public/4027ec902e239c93eaaa8714f173bfcf/3814572266302145/815525683663273/8959396615508843/latest.html>

001_Importar_arquivos_raw.ipynb

Este notebook tem como objetivo importar o dataset Kaggle sobre os filmes e seriados da Netflix, para o ambiente do Databricks. É o segundo a ser executado.

<https://databricks-prod-cloudfront.cloud.databricks.com/public/4027ec902e239c93eaaa8714f173bfcf/3814572266302145/4470911049895348/8959396615508843/latest.html>

002_Carregar_Camada_Bronze.ipynb

Este notebook consiste na ingestão do arquivo csv para uma tabela em formato delta. Não há qualquer modificação, apenas recepção dos dados brutos. É O terceiro a ser executado.

<https://databricks-prod-cloudfront.cloud.databricks.com/public/4027ec902e239c93eaaa8714f173bfcf/3814572266302145/910373024565501/8959396615508843/latest.html>

003_Transformacoes_Camada_Silver_floco_neve.ipynb

Este notebook é voltado para a limpeza, transformação e padronização dos dados. Abrange também o tratamento de nulos e normalização de tabelas. É o quarto a ser executado.

<https://databricks-prod-cloudfront.cloud.databricks.com/public/4027ec902e239c93eaaa8714f173bfcf/3814572266302145/4178132741742921/8959396615508843/latest.html>

Notebook 004_Camada_Gold_Floco_Neve.ipynb


Este notebook tem como objetivo realizar agregações analíticas, análise temporal e consultas de métricas de desempenho (ranqueamento). É o quarto notebook a ser executado.

<https://databricks-prod-cloudfront.cloud.databricks.com/public/4027ec902e239c93eaaa8714f173bcfc/3814572266302145/2676970212451849/8959396615508843/latest.html>


Modelo e Catálogo de dados

Foi adotado o esquema floco de neve, para melhor tratamento de nulos e arrays de valores. Como exemplo, podemos citar que um conteúdo possui vários gêneros, vários diretores e vários atores atuando. O modelo floco de neve permite resolver melhor os relacionamentos de muitos para muitos, por meio de junções.

A figura abaixo mostra o modelo do esquema:



Evidência de criação de catálogos para cada camada:



databricks

New

- Workspace
- Recents
- Search
- Catalog**
- Workflows
- Compute
- Machine Learning
- Experiments

Data

Databases ✓

Filter Databases

- bronze
- default
- gold
- silver**

tabelas
esquema
flocos de neve

Tabelas geradas a partir da tabela flat.

tabela flat usada para as transformações iniciais

Tables

Filter Tables

- conteudo_ator_junc
- conteudo_diretor_junc
- conteudo_genero_junc
- conteudo_pais_junc
- dim_ator
- dim_date
- dim_diretor
- dim_genero
- dim_pais
- dim_tipo_conteudo
- fato_netflix
- netflix_titles_clean

databricks

New

- Workspace
- Recents
- Search
- Catalog**
- Workflows
- Compute
- Machine Learning
- Experiments

Data

Databases ✓

Filter Databases

- bronze
- default
- gold**
- silver

Tabelas do esquema flocos de neve na camada gold. Possuem as mesmas estruturas do esquema flocos de neve na camada silver.

Tables

Filter Tables

- conteudo_ator_junc
- conteudo_diretor_junc
- conteudo_genero_junc
- conteudo_pais_junc
- dim_ator
- dim_date
- dim_diretor
- dim_genero
- dim_pais
- dim_tipo_conteudo
- fato_netflix

Foi criado o catálogo de dados com descrição de colunas na camada ouro, em: https://github.com/Andrea68A/Puc_Ciencia_Dados/blob/MVP_Engenharia_Dados/Catalogo_camada_gold_versao2.pdf.

O código do notebook da camada ouro mostra a criação de comentários para os campos de cada tabela. A figura a seguir é uma evidência:

```
spark.sql("ALTER TABLE gold.fato_netflix ALTER COLUMN show_id COMMENT 'identificador de show'")
spark.sql("ALTER TABLE gold.fato_netflix ALTER COLUMN title COMMENT 'titulo'")
spark.sql("ALTER TABLE gold.fato_netflix ALTER COLUMN content_type_id COMMENT 'identificador de tipo de conteudo'")
spark.sql("ALTER TABLE gold.fato_netflix ALTER COLUMN date_added COMMENT 'data cadastrado na Netflix'")
spark.sql("ALTER TABLE gold.fato_netflix ALTER COLUMN release_year COMMENT 'ano de lancamento do filme ou seriado'")
spark.sql("ALTER TABLE gold.fato_netflix ALTER COLUMN duration_minutes COMMENT 'duracao em minutos do filme'")
spark.sql("ALTER TABLE gold.fato_netflix ALTER COLUMN duration_seasons COMMENT 'duracao em temporadas do seriado'")
spark.sql("ALTER TABLE gold.fato_netflix ALTER COLUMN rating COMMENT 'classificacao da faixa etaria'")
spark.sql("ALTER TABLE gold.fato_netflix ALTER COLUMN description COMMENT 'descricao do titulo'")
```

Modelo de Pipeline

Foi gerado o seguinte modelo de pipeline:

Raw (CSV) ➔ Bronze (Dados Brutos) ➔ Silver (Dados Limpos/Transformados, com geração do esquema floco de neve) ➔ Gold (Agregados Analíticos).

A figura mostra a evidência das camadas no Databricks Community Edition:

Workspace

> Home

> Workspace

> Shared

> Users

> Exercicio

> MVP_Engenharia_Dados

> Notebooks

> Rascunho_MVP

Trash

Workspace >

MVP_Engenharia_Dados

Share

Crea

Name	Type	Owner	Created at
000_Configurar_DBFS_e_pastas	Notebook	andreaaraujoalves@gmail.c...	Apr 02, 2025, 01:26 PM
001_Importar_arquivos_raw	Notebook	andreaaraujoalves@gmail.c...	Apr 05, 2025, 06:17 PM
002_Carregar_Camada_Bronze	Notebook	andreaaraujoalves@gmail.c...	Apr 02, 2025, 09:05 PM
003_Transformacoes_Camada_Silver_floc...	Notebook	andreaaraujoalves@gmail.c...	Apr 06, 2025, 06:38 PM
004_Camada_Gold_Floco_Neve	Notebook	andreaaraujoalves@gmail.c...	Apr 09, 2025, 10:49 PM

Pipeline de Dados e ETL

Camada Raw

O objetivo da camada raw consiste em carregar o arquivo CSV para a ferramenta de nuvem Databricks Community Edition.

Camada Bronze

O objetivo da camada bronze consiste na ingestão de dados brutos, sem haver quaisquer transformações.

ETL:

1. Carregar o CSV para Databricks.
2. Salvar em formato Delta Lake para compressão e versionamento, usando Python e Spark.SQL

Camada Silver

O objetivo da camada silver consiste na limpeza e no enriquecimento do modelo.

ETL:

1. Tratar valores nulos e arrays(diretor, país).
2. Transformação de tipo e padronização de datas (**date_added**). O tipo de dados no dataset original era string e foi convertido em data no formato "YYYY-MM-DD". -
3. Separar **listed_in** em múltiplos gêneros Ex: "Comédia", Dramas" para tabela dimensão de gêneros, contendo os valores "Comédia", "Dramas".
4. Separar a duração em minutos para filmes e em número de temporadas para séries.

Camada Gold

O objetivo da camada ouro consiste em realizar agregações analíticas, análise temporal e consultas de métricas de desempenho (ranqueamento)

ETL:

1. Criar tabelas agregadas:
 - Conteúdo por ano (release_year).
 - Top 10 países, gêneros, diretores.

Consultas Analíticas

1. **Temporais:**
 - Crescimento de conteúdo por ANO (release_year).
 - Tendência mensal e anual de adições à plataforma (date_added).
2. **Gênero/País:**
 - Gêneros mais populares por país (ex: "Dramas" na Índia).
3. **Métricas TOP 10:**
 - Diretores mais frequentes, atores mais recorrentes, países com maior produção.

Autoavaliação e Conclusões

Foi possível responder as perguntas de negócio contidas na seção “**Definição do problema**”.

Inicialmente, foi pensado em usar tabela flat, que gera redundância no tratamento de dados e consultas com muitos valores e colunas, consequentemente com tabelas maiores. Como vantagem da tabela flat, destaca-se não necessitar de junções. Porém, esta abordagem foi abandonada devido à complexidade no tratamento de arrays.

O pipeline apresenta eficiência no tratamento de arrays e de nulos, na verificação de integridade das chaves e relacionamentos, devido à normalização, por meio de tabelas de junção (ex: conteúdo_diretor_junc). Como foi usada a normalização para os relacionamentos muitos para muitos (tabelas de junção), algumas consultas se tornaram

mais custosas em termos de processamento porque exigiram JOIN. Porém, o impacto de processamento não foi relevante porque a base de dados possui menos de 9000 linhas.

As agregações na camada gold permitiram identificar padrões claros, como: países maiores produtores de conteúdo, países com maior produção por gênero. Como exemplo, podemos mencionar que os Estados Unidos é o país que mais lança dramas.

A partição da tabela fato Netflix por ano de lançamento permitiu maior eficiência no desempenho de leitura e escrita nas consultas SQL.

Cerca de 70% do catálogo são filmes, com crescimento exponencial no lançamento a partir de 2015.

Como ponto de melhoria, deveria ser eliminada a coluna de classificação etária, que foi pouco abordada neste projeto.